年收入和風險態度對壽險購買金額的影響分析

統計115 H24116065 黃柏翰
統計115 H24116112 張智賢
統計115 B14101314 吳意漳

壹、前言

一、研究背景

人壽保險是個人財務規劃與風險管理的重要工具，過去關於保險需求的研究多著重於經濟因素，例如收入、家庭結構或財富水準。然而，除經濟能力外，個人的心理特質，特別是「風險態度」，理論上也應對保險購買決策產生顯著影響。

本研究採用Neter等人(1996)所提供的資料集，針對企業經理人這一特定族群進行探討。經理人通常具有較高的收入水準與財務自主權，其保險決策更能反映個人偏好而非僅是基本保障需求。

二、研究問題與分析目標

透過建立統計模型，分析經理人的年收入與風險趨避程度，試圖釐清並預測經濟變數與心理變數如何共同影響人壽保險的持有額度，並進一步探討這些影響是否存在非線性的邊際效應。

三、資料分析

表1:原始資料

	anninc	riskaver	lifeins
1	45.010	6	91
2	57.204	4	162
3	26.852	5	11
4	66.290	7	240
5	40.964	5	73

6	72.996	10	311
7	79.380	1	316
8	52.766	8	154
9	55.916	6	164
10	38.122	4	54
11	35.840	6	53
12	75.796	9	326
13	37.408	5	55
14	54.376	2	130
15	46.186	7	112
16	46.130	4	91
17	30.366	3	14
18	39.060	5	63

anninc (Average Annual Income)(X_{i1})

- 經理人的平均年度收入。
- 單位:千美元。

riskaver (Risk Aversion Score)(X_{i2})

- 風險趨避分數:衡量經理人對風險態度的心理測驗分數。
- 數值意義:分數越高，代表該經理人越趨避風險，即個性越保守謹慎。

lifeins (Life Insurance)(Y)

- 經理人持有的人壽保險總金額。
- 單位:千美元。

- 自變數與反應變數之間的線性關係:

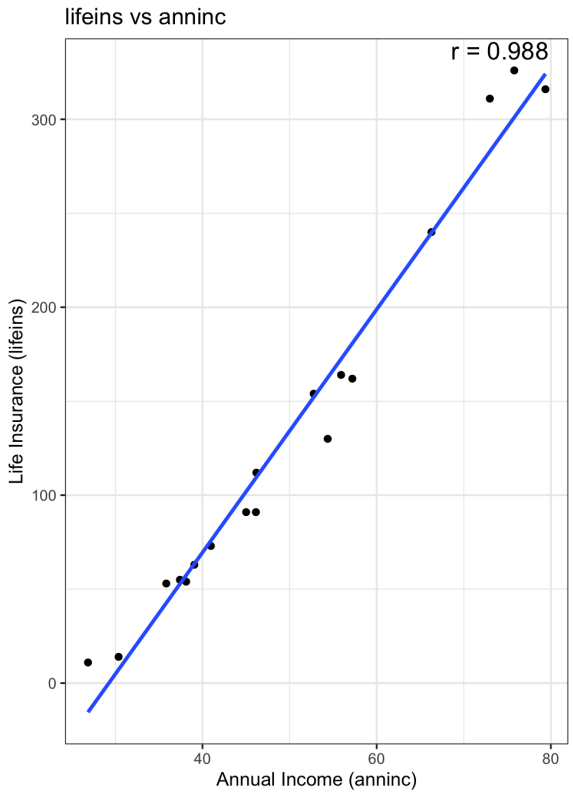

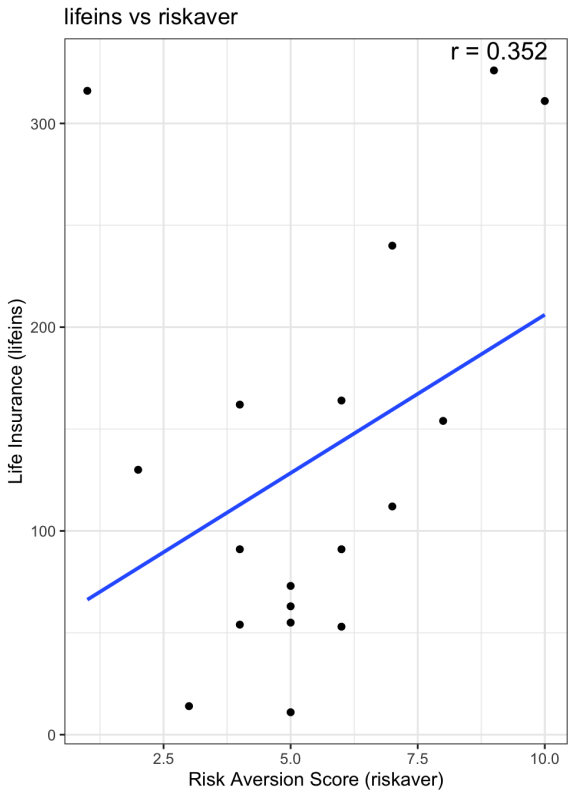

顯示反應變數Y跟自變數X_{i1}高度正相關, 而反應變數Y跟自變數X_{i2}有輕微正相關

- 檢查自變數間共線性:

首先先計算兩個自變數之間的相關係數, 再算出VIF值, 可以得到:

$$r = 0.254488$$

$$VIF = \frac{1}{1-r^2} = 1.069249 \approx 1$$

因為VIF值≈1 所以自變數之間幾乎沒有線性關係

貳、分析方法與結果

一、原始模型:

- **母體迴歸方程式**:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \varepsilon_i,\ \ i = 1\,,2\,,\ldots,18$$

$Y_i =$ 第 i 個經理人持有的壽險總金額

$X_{i1} =$ 第 i 個經理人的年平均收入

$X_{i2} =$ 第 i 個經理人的風險趨避分數

$\beta_0 =$ 母體迴歸方程式之截距項

$\beta_1 =$ 第 1 個解釋變數之母體迴歸方程式係數

$\beta_2 =$ 第 2 個解釋變數之母體迴歸方程式係數

$\varepsilon_i =$ 第 i 個樣本誤差項

其中的模型假設:$\varepsilon_i \sim N(0, \sigma^2)$, ε_i 之間iid

- **樣本迴歸方程式**:

我們要透過樣本資訊找出一條樣本回歸方程式用以估計母體回歸程式, **其中** e_i (residual) **用來估算誤差項** ε_i:

$$\widehat{Y_i} = \widehat{\beta_0} + \widehat{\beta_1} X_{i1} + \widehat{\beta_2} X_{i2} \rightarrow E(Y_i) = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2}$$

$$e_i = Y_i - \hat{Y}_i \rightarrow \varepsilon_i = Y_i - E(Y_i)$$

這邊我們再利用LSE算出$\widehat{\beta_0}$, $\widehat{\beta_1}$, $\widehat{\beta_2}$來估計 β_0,β_1,β_2

$$\hat{\beta}_1 = \frac{S_{x_2x_2}S_{x_1y} - S_{x_1x_2}S_{x_2y}}{S_{x_1x_1}S_{x_2x_2} - (S_{x_1x_2})^2} \quad \hat{\beta}_2 = \frac{S_{x_1x_1}S_{x_2y} - S_{x_1x_2}S_{x_1y}}{S_{x_1x_1}S_{x_2x_2} - (S_{x_1x_2})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}_1 - \hat{\beta}_2\bar{x}_2$$

其中:

$$S_{x_1x_1} = \sum(x_{i1} - \bar{x}_1)^2 \quad S_{x_2x_2} = \sum(x_{i2} - \bar{x}_2)^2 \quad S_{x_1x_2} = \sum(x_{i1} - \bar{x}_1)(x_{i2} - \bar{x}_2)$$

$$S_{x_1y} = \sum(x_{i2} - \bar{x}_2)(y_i - \bar{y}) \quad S_{x_2y} = \sum(x_{i2} - \bar{x}_2)(y_i - \bar{y})$$

$$\widehat{\beta_0} = -205.7187, \quad \widehat{\beta_1} = 6.2880, \quad \widehat{\beta_2} = 4.7376$$

最後可以得到樣本回歸方程式為:

$$\widehat{Y_i} = -205.7187 + 6.288X_{i1} + 4.7376X_{i2}$$

接下來做整體F檢定和個別t檢定, 檢定整體模型及個別變數對預設結果是否有效

Overall F-test:

$$H_0 : \beta_1 = \beta_2 = 0$$

$$H_a : \beta_j \neq 0$$

檢定統計量:

$$F = \frac{MSR}{MSE} = \frac{\frac{SSR}{k-1}}{\frac{SSE}{n-k}} = \frac{\frac{\sum_{i=1}^{n}(\hat{Y}_i - \bar{Y})^2}{k-1}}{\frac{\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2}{n-k}} \sim F(k-1, n-k)$$

檢定結果:

F = 542.3 , p-value = 1.026e-14 < 0.05 ⇒ 拒絕虛無假設

Individual t-tests:

$$H_0 : \beta_j = 0$$

$$H_a : \beta_j \neq 0$$

檢定統計量:

$$t = \frac{\widehat{\beta}_j - 0}{SE(\widehat{\beta}_j)} \sim t(n-k)$$

檢定結果:

H_0	statistic	p-value	conclusion
$\beta_0 = 0$	-18.057	1.38e-11	reject H_0
$\beta_1 = 0$	30.801	5.63e-15	
$\beta_2 = 0$	3.438	0.00366	

整體 F 檢定顯示模型在統計上具有顯著的解釋能力，而個別 t 檢定亦顯示各自變數的係數均顯著不為零，表示 anninc與 riskaver 在控制其他變數後仍各自對 lifeins 具有顯著的影響力。

二、模型殘差診斷:

1. Shapiro–Wilk Test檢定常態性

$$H_0: \varepsilon_i \text{ 服從常態分佈}$$

$$H_a: \varepsilon_i \text{ 不服從常態分佈}$$

Shapiro–Wilk 的檢定統計量:

$$W = \frac{\left(\sum_{i=1}^{n} a_i x_{(i)}\right)^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

檢定結果:

W＝0.94479　p-value = 0.3492 > 0.05 ⇒ 不拒絕虛無假設

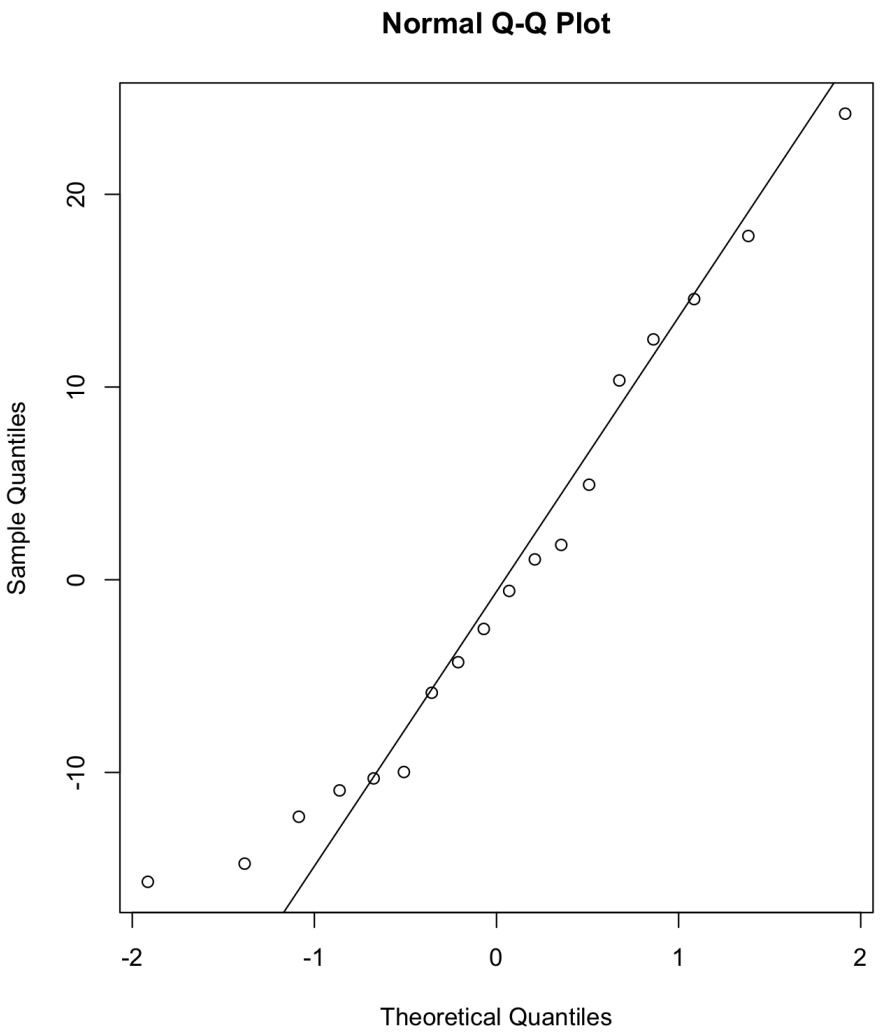

2. Studentized Breusch-Pagan test檢定同質變異數:

$$H_0: \sigma_1^2 = \sigma_2^2 = \dots = \sigma_{18}^2 = \sigma^2$$

$$H_a: \sigma_i^2 \text{ 不完全相等}$$

Studentized Breusch-Pagan的檢定統計量:

$BP = n \times R_{aux}^2$

n：樣本數

R_{aux}^2：輔助迴歸模型($e_i^2 = \gamma_0 + \gamma_1 X_{i1} + \gamma_2 X_{i2} + \tau_i$)的$R^2$

e_i^2：原始迴歸模型之 residual

檢定結果:

BP＝0.94479, df = 2, p-value = 0.4361 > 0.05 ⇒ 不拒絕虛無假設

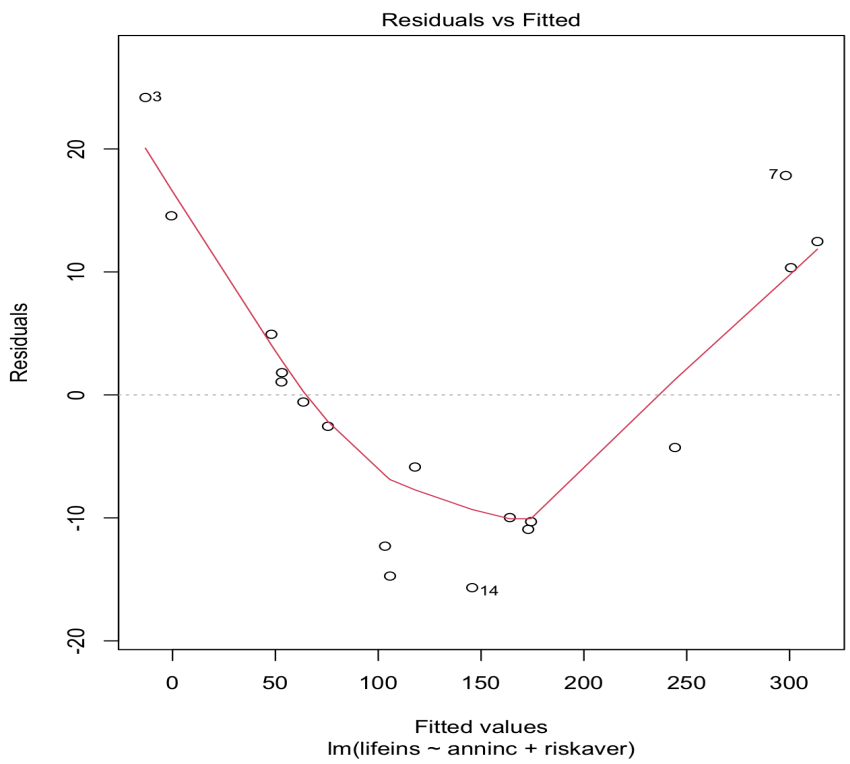

3.

4. Durbin-Watson test檢定殘差之間有無序列相關:

H_0 : 殘差之間獨立

H_a ： 殘差之間不獨立

Durbin-Watson的檢定統計量:

$$DW = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} e_t^2}$$

檢定結果:

DW＝1.9815, p-value =0.5562 > 0.05 ⇒ 不拒絕虛無假設

迴歸模型已滿足線性回歸之主要統計前提假設, 因此模型的估計結果可視為可靠且具統計效度。

三、修正模型:

原始model的殘差與擬合值圖:

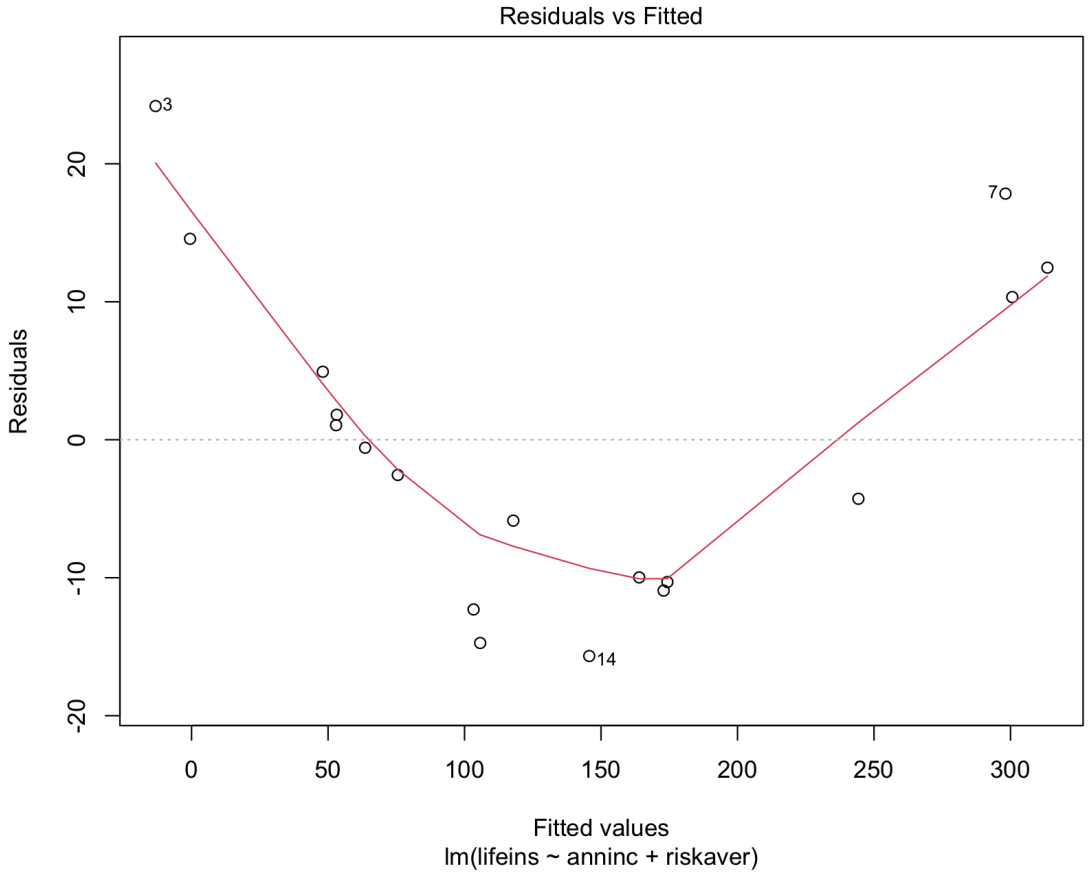

殘差與擬合值圖中，殘差分佈呈現明顯的U型曲線趨勢，而非隨機散佈在零線周圍。此模式顯示模型可能存在非線性關係未被捕捉的問題，單純的線性模型設定不足以充分解釋變數間的關係。

為改善模型適配度，將考慮在模型中加入預測變數的二次項，以捕捉資料中疑似存在的二次關係，使模型更符合資料的實際結構。

接下來我們要找最適合的模型，我們的候選模型分別有：

model 1 : 加上anninc^2

$$\hat{Y}_i = \widehat{\beta_0} + \widehat{\beta_1} X_{i1} + \widehat{\beta_2} X_{i2} + \widehat{\beta_3} {X_{i1}}^2, \quad i = 1, 2, \ldots, 18$$

model 2 : 加上riskaver^2

$$\hat{Y}_i = \widehat{\beta_0} + \widehat{\beta_1} X_{i1} + \widehat{\beta_2} X_{i2} + \widehat{\beta_3} {X_{i2}}^2, \quad i = 1, 2, \ldots, 18$$

model 3 : 加上anninc^2 和 riskaver^2

$$\hat{Y}_i = \widehat{\beta_0} + \widehat{\beta_1}X_{i1} + \widehat{\beta_2}X_{i2} + \widehat{\beta_3}{X_{i1}}^2 + \widehat{\beta_4}{X_{i2}}^2,\ \ i = 1, 2, \ldots, 18$$

接著計算各模型的AIC值去相互比較哪種模型才是最佳的

AIC (Akaike Information Criterion) 是一種衡量統計模型好壞的指標，AIC值越小代表模型越好，公式如下：

$$AIC = -2 * \log(L) + 2k$$

其中，L：模型的概似函數值（Likelihood）

反映模型解釋資料的好壞,擬合越好，L越大，-2log(L)越小

k：模型中參數的總數

包括：截距項、迴歸係數、誤差項方差等，參數越多，2k 越大

計算各模型的AIC值去相互比較哪種模型才是最佳的，結果如下：

	AIC值	排名(小到大)
model 1	86.78	1
model 2	142.72	3
model 3	88.62	2

因此我們選擇 model 1當作修正後的模型。

再來一樣利用LSE算出 $\widehat{\beta_0}$, $\widehat{\beta_1}$, $\widehat{\beta_2}$, $\widehat{\beta_3}$

$$\widehat{\beta_0} = -73.46051,\ \widehat{\beta_1} = 0.79596,\ \widehat{\beta_2} = 5.40039,\ \widehat{\beta_3} = 0.05087$$

最後可以得到修正後的樣本回歸方程式為：

$$\widehat{Y_i} = -73.46051 + 0.79596X_{i1} + 5.40039X_{i2} + 0.05087{X_{i1}}^2$$

接下來同樣對β_j做整體的F檢定和個別的t檢定，結果如下表：

	H_0	statistic	p-value	conclusion
F檢定	$\beta_1 = \beta_2 = \beta_3 = 0$	1.096e+04	2.2e-16	reject H_0
t檢定	$\beta_0 = 0$	-11.001	2.83e-08	
	$\beta_1 = 0$	2.991	0.00971	
	$\beta_2 = 0$	21.262	4.68e-12	
	$\beta_3 = 0$	20.847	6.12e-12	

模型整體具有統計顯著性，且所有自變數在控制其他變數後皆對lifeins有顯著的線性影響，表示 anninc, riskaver, anninc^2 均能夠有效解釋保險金額的變異。

再來，我們針對修正後的模型去做殘差診斷是否符合，首先我們可以發現加了二次項後原本殘差分佈的U型曲線趨勢就不見了（如下圖），但同時也放大了某些觀察值與模型預測之間的差距，導致有原本不明顯的異常觀察值在新的模型下變得更顯著。

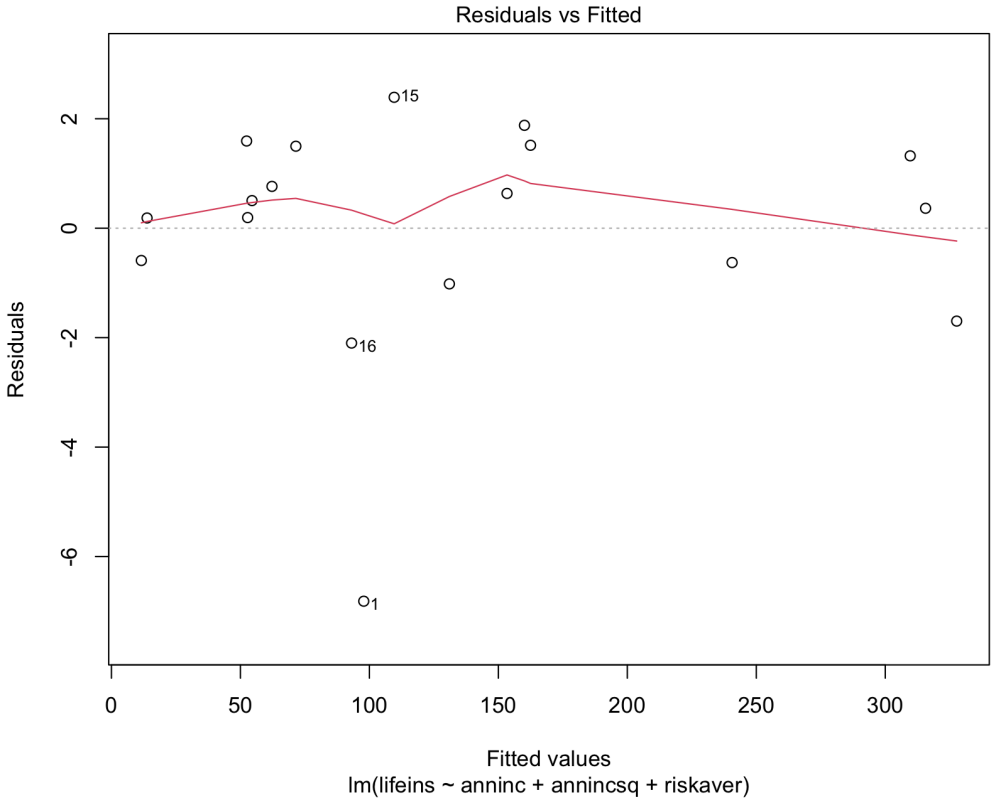

這筆異常值也導致後續的殘差常態性檢查出了問題。針對修正模型做Shapiro–Wilk Test之後，我們得的檢定統計量是 W = 0.8075, p-value = 0.001942 結果是拒絕虛無假設的，也就是沒有足夠證據相信殘差符合常態分佈。可能會導致後續的推論可靠性不足。

我們再來計算各觀測值的影響診斷指標，包含 Cook's distance、Leverage、DFFITS 以及 DFBETAS，以判斷是否存在對模型估計具有過度影響的資料點。根據迴歸診斷結果，我們發現第1筆資料在三項指標中皆呈現明顯偏大：

Cook's Distance：

衡量如果把第i筆資料刪掉，整個迴歸模型會改變多少

$$D_i = \frac{\left(\hat{Y} - \hat{Y}_{(i)}\right)' \left(\hat{Y} - \hat{Y}_{(i)}\right)}{p\,\mathrm{MSE}} = \frac{e_i^2}{p\,\mathrm{MSE}} \left(\frac{h_i}{(1-h_i)^2}\right)$$

高於$\frac{4}{n}$的判斷基準，顯示刪除該觀測值將使模型整體的迴歸係數估計產生明顯變動。

Leverage：

偵測 X（預測變數）空間中的離群值

$$h_i = h_{ii} = \frac{\partial \hat{y}_i}{\partial y_i}$$

顯著高於常用基準 2(p+1)/n2(p+1)/n，表示該點在自變數空間的位置十分偏離其他樣本，是可能的高槓桿點（high leverage point）。

DFFITS (Difference in Fits)：

如果把第i筆資料刪掉，該點自己的預測值$\widehat{Y}_i$會改變多少

$$\text{DFFITS}_i = \frac{\hat{Y}_i - \hat{Y}_{i(i)}}{\sqrt{\text{MSE}_{(i)}\, h_i}}$$

DFFITS 超過$\frac{\pm 2p}{n}$的標準界線，意味著該觀測值對模型的預測值造成過度影響。

DFBETAS (Difference in Betas)：

如果把第i筆資料刪掉，第k個迴歸係數$\widehat{\beta}_k$會改變多少

$$\text{DFBETAS}_{ik} = \frac{\hat{\beta}_k - \hat{\beta}_{k(i)}}{\sqrt{\text{MSE}_{(i)}\, c_{kk}}}$$

DFBETAS 在多個迴歸係數上超過$\frac{\pm 2p}{n}$，表示此筆資料會大幅改變單一迴歸係數的估計。

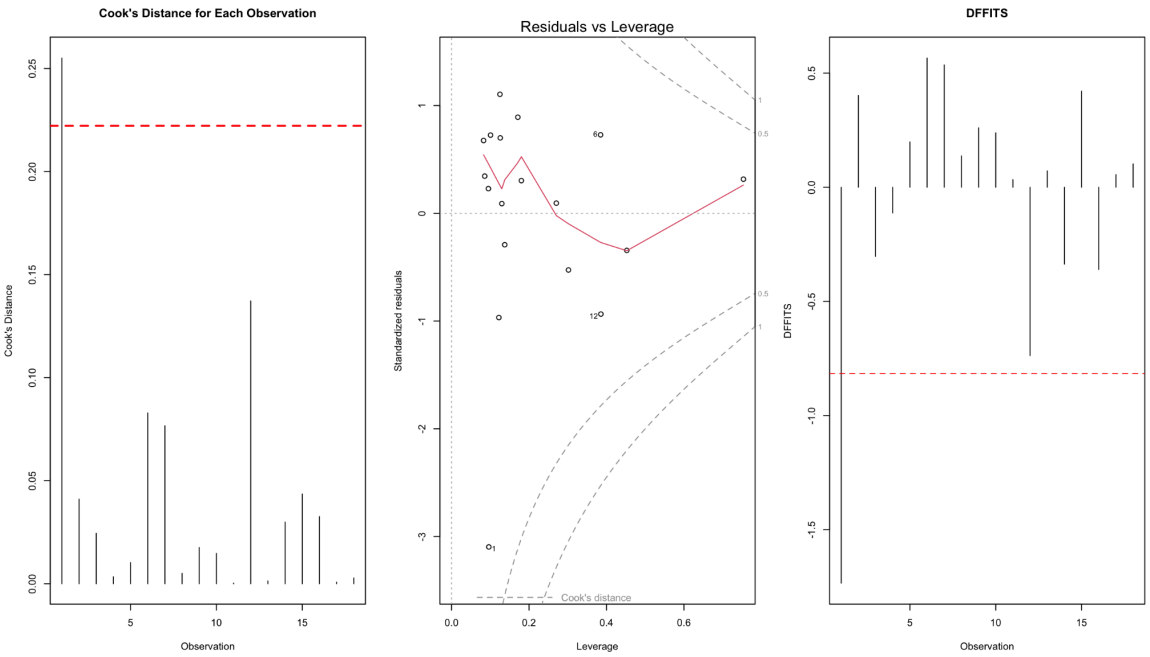
Cook's Distance for Each Observation
Cook's Distance
Observation
Residuals vs Leverage
Standardized residuals
Leverage
Cook's distance
DFFITS
DFFITS
Observation

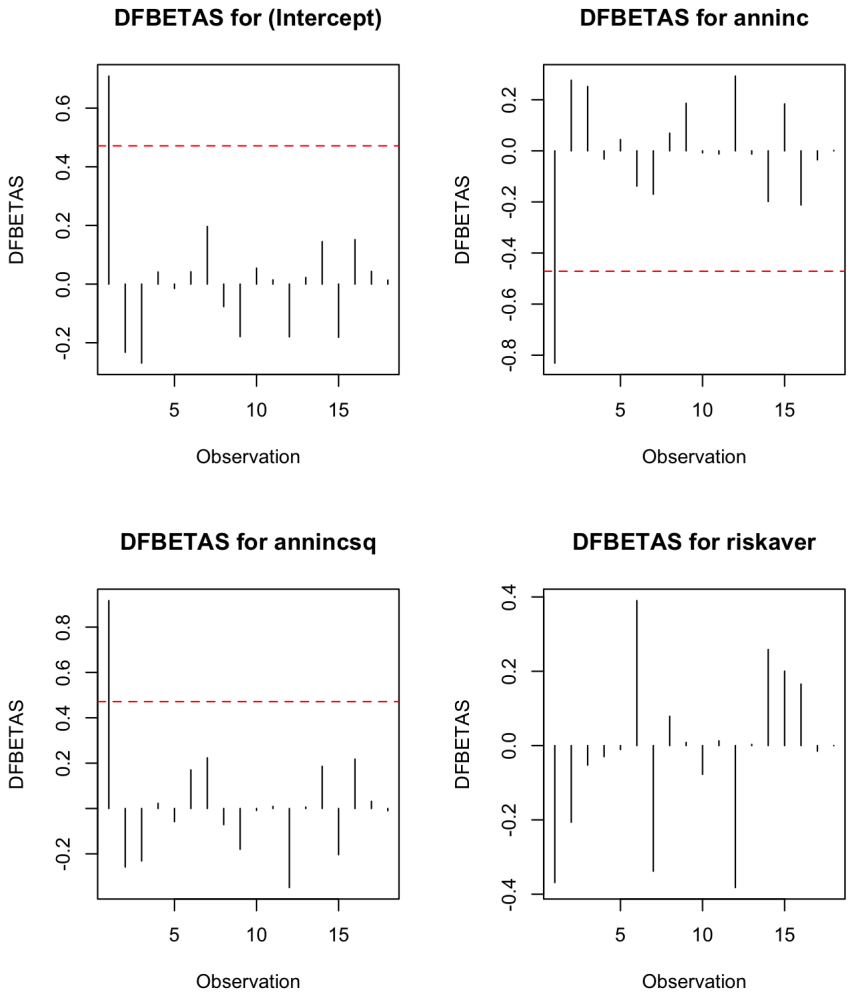
DFBETAS for (Intercept)
DFBETAS
Observation
DFBETAS for anninc
DFBETAS
Observation
DFBETAS for annincsq
DFBETAS
Observation
DFBETAS for riskaver
DFBETAS
Observation

綜合上述指標，第1筆資料可被歸類為典型的影響點(influential point)。此觀測值的存在導致模型殘差分佈偏離常態、影響回歸係數穩定性。

因此，在後續的分析中，我們將進行敏感性分析(sensitivity analysis)，比較:

model 0 : 原始模型保留全部的資料

model 1 : 修正後的模型且保留第1筆資料

model new: 修正後的模型且移除第1筆資料

一樣利用LSE估計算出$\widehat{\beta_0}$, $\widehat{\beta_1}$, $\widehat{\beta_2}$, $\widehat{\beta_3}$

$$\widehat{\beta_0} = -76.218987,\ \widehat{\beta_1} = 0.92474,\ \widehat{\beta_2} = 5.454926,\ \widehat{\beta_3} = 0.049562$$

最後可以得到修正後的樣本回歸方程式為:

$$\widehat{Y_{new\,i}} = -76.218987 + 0.92474X_{i1} + 5.454926X_{i2} + 0.049562X_{i1}^{2}$$

	H_0	statistic	p-value	conclusion
F檢定	$\beta_1 = \beta_2 = \beta_3 = 0$	3.193e+04	2.2e-16	reject H_0
t檢定	$\beta_0 = 0$	-19.422	5.50e-11	
	$\beta_1 = 0$	5.895	5.28e-05	
	$\beta_2 = 0$	36.780	1.58e-14	
	$\beta_3 = 0$	34.363	3.80e-14	

三種模型的綜合比較:

		model 0	model 1	model new
迴歸係數穩定性	偏t檢定	均拒絕 H_0 : $\beta_j = 0$		
	β_j的估計值	係數正負均一致		
	MSE	12.66	2.315	1.349
殘差診斷	常態性	不拒絕 H_0	拒絕 H_0	不拒絕 H_0
	同質變異數	不拒絕 H_0	不拒絕 H_0	不拒絕 H_0
	序列相關	無顯著相關		
模型適配度	Adjusted R^2	0.9845	0.9995	0.9998
	AIC	147.1917	86.78402	63.85793

參、結論

一、研究結果

本研究探討了企業經理人的經濟能力(年收入)與心理特質(風險趨避程度)如何共同影響其人壽保險的持有額度。透過對 lifeins 資料集的深入分析，我們不僅驗證了變數間的關聯性，更透過嚴謹的模型診斷過程，修正了原始模型的不足。

模型修正與非線性關係的發現在於模型診斷階段，雖然基礎的複迴歸模型顯示收入與風險態度皆有顯著影響，但殘差分析(Residual Plot)卻揭示了明顯的 U 型趨勢，這項視覺證據強烈暗示了收入對保額的影響並非單純的直線關係。基於此發現，我們引入了收入的平方項(anninc^2)進行多項式迴歸。修正後的模型不僅消除了殘差的系統性樣態，更顯著提升了模型的解釋力，證明了經理人的保險需求隨著收入增長呈現非線性的邊際變化。

最終模型證實，在控制了收入水準後，「風險趨避分數」依然對壽險保額具有顯著的正向影響。這驗證了我們的研究假設：除了客觀的財富水準外，主觀的心理特質亦是決策關鍵，個性越保守、越傾向規避風險的經理人，確實會購買更高額度的保險來尋求保障。這說明了在預測保險需求時，不能僅考量經濟變數，心理變數亦不可或缺。

本研究旨在探討企業經理人的年收入與風險趨避態度如何影響其人壽保險持有額度。透過對 lifeins 資料集的三階段模型優化過程，我們不僅確立了關鍵的影響因子，更建構出具備最佳解釋力與穩健性的統計模型。

第一階段：線性假設的檢驗與侷限 (Model 0)

研究初期，我們建立基礎線性迴歸模型 (Model 0) 進行探索。雖然初步結果顯示年收入與風險態度皆具統計顯著性，但模型診斷揭示了嚴重問題：殘差圖呈現明顯的 U 型系統性偏差 。此證據強烈顯示，單純的線性關係不足以描述經理人的投保行為，收入對保額的影響並非固定不變的線性增長，模型存在設定偏誤 (Misspecification)。

第二階段：非線性關係的確立 (Model 1)

基於殘差診斷的發現，本研究引入收入平方項 ($anninc^2$) 建構多項式模型 (Model 1) 。結果顯示，平方項具有高度顯著性，且殘差圖中的 U 型趨勢完全消除，轉為隨機散佈。此階段證實了收入與保額之間存在非線性的邊際效應，模型解釋力 (R^2_{adj}) 顯著提升，成功解決了 Model 0 的結構性缺失 。

第三階段：極端值的排除與模型優化 (Model New)

儘管 Model 1 修正了函數形式，但透過影響點分析（如 Cook's Distance），我們發現少數極端個案對參數估計產生了過度的拉力 。為確保模型能反映大多數經理人的普遍行為，本研究移除了這些強影響點，建立最終模型 (Model New)。比較結果顯示，Model New 擁有最低的 AIC 指標與最高的解釋力，證明在排除極端值干擾後，模型對數據的適配度達到最佳狀態。

綜合結論

綜上所述，本研究最終採用 Model New 作為解釋經理人壽險需求的最佳模型。研究證實，在控制了收入的非線性效應後，「風險趨避程度」依然是影響保險決策的關鍵心理因素——個性越保守的經理人，確實傾向購買更高額度的保險。本研究展示了透過嚴謹的模型診斷與優化程序，能有效提升統計推論的準確性與可信度。

二、研究限制與未來方向

儘管本研究透過多項式迴歸模型成功解釋了經理人的收入、風險態度與壽險保額之間的關係，但受限於資料本質，本研究仍存在以下限制：

1. 樣本數過少
   本研究僅包含 18 位 經理人的觀測值 1。在統計學上，過小的樣本數會導致：
   - 檢定力不足：可能難以偵測到較微弱但真實存在的效應。
   - 估計不穩定：迴歸係數容易受到單一異常值或高槓桿點的劇烈影響。如我們在影響點分析中所見，少數幾位特殊的經理人可能就左右了整條迴歸線的走勢。
2. 遺漏變數偏誤
   本模型僅考慮「年收入」與「風險態度」兩個變數。然而，現實中影響壽險需求的因素眾多，例如：年齡、家庭成員數、撫養比或現有資產。由於資料集未包含這些變數，若這些遺漏變數與收入高度相關（例如年紀大的經理人通常收入也高），可能會導致我們高估或低估收入對保額的真實影響力。
3. 外推性的限制
   本研究樣本特定為「企業經理人」。此族群通常擁有較高的收入與特定的社經地位。因此，本研究之模型結論（如收入平方項的邊際效應）可能無法直接推論至其他職業群體（如藍領階級）或整體社會大眾。
4. 因果推論的限制
   本研究為橫斷面的觀察性研究，僅能證實變數間的「相關性」，無法斷定絕對的「因果關係」。例如，雖然高收入與高保額相關，但也可能是因為這類人擁有更複雜的資產配置需求所致。

針對上述限制，可對未來相關研究提出以下建議：

1. 擴大樣本規模與多樣性
   建議未來研究應收集更多樣本，並納入不同職業類別與年齡層的受訪者，以驗證本研究發現的「非線性收入效應」是否在不同群體中具有普適性。
2. 納入更多人口統計變數
   可在模型中加入「年齡」與「家庭撫養人數」作為控制變數。
   - 書中有其他案例（如 ICU 研究）顯示年齡是重要的預測因子。在保險議題上，年齡越大或撫養責任越重，保險需求通常越高。控制這些變數後，能更精準地分離出「風險態度」的純粹影響力。

3. 縱貫性研究

若數據允許，可進行長期追蹤研究，觀察同一位經理人在職涯發展過程中，隨著收入增長與家庭結構改變，其風險態度與保險需求的動態變化路徑。

肆、參考資料

1. Breusch, T. S., & Pagan, A. R. (1979). A simple test for heteroscedasticity and random coefficient variation. Econometrica, 47(5), 1287–1294.
2. Durbin, J., & Watson, G. S. (1951). Testing for serial correlation in least squares regression. II. Biometrika, 38(1/2), 159–178.
3. Heiberger, R. M., & Holland, B. (2015). Statistical Analysis and Data Display: An Intermediate Course with Examples in R (2nd ed.). Springer.
4. Koenker, R. (1981). A note on homoscedasticity tests. Econometrica, 49(1), 107–112.
5. Shapiro, S. S., & Wilk, M. B. (1965). An analysis of variance test for normality (with discussion). Biometrika, 52(3/4), 591–611.
6. Weisberg, S. (1985). *Applied Linear Regression* (2nd ed.). Wiley.